

南開大學
Nankai University

基于大语言模型的知识图谱构建方法研究

博士研究生学术汇报

张 三
南开大学　计算机学院
2026 年 5 月 24 日

允公允能　日新月異

目录

1. 背景介绍
2. 相关工作
3. 研究方法
4. 实验结果
5. 总结与展望

目录

1. 背景介绍
2. 相关工作
3. 研究方法
4. 实验结果
5. 总结与展望

研究背景

- 知识图谱（Knowledge Graph）是人工智能的重要基础设施
- 大语言模型（LLM）为知识图谱构建提供了新的范式[1]
- 现有方法面临的主要挑战：
  - 实体识别与链接的准确率有待提升
  - 关系抽取在长尾分布下效果不佳
  - 缺乏统一的端到端构建框架

> 本研究致力于结合 LLM 的语义理解能力，构建高质量的领域知识图谱。

[1] J. Wei et al. "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2022.

基本概念

知识图谱 (Knowledge Graph)

知识图谱是一种用图结构来建模和存储现实世界中实体及其关系的技术，通常表示为三元组集合 $\mathcal{G} = \{(h, r, t)\}$，其中 $h, t \in \mathcal{E}$（实体集），$r \in \mathcal{R}$（关系集）。

TransE 评分函数

对于正确的三元组 (h, r, t)，嵌入向量满足 $\boldsymbol{h} + \boldsymbol{r} \approx \boldsymbol{t}$，即评分函数 $f(h, r, t) = \|\boldsymbol{h} + \boldsymbol{r} - \boldsymbol{t}\|$ 趋近于零。[a]

[a] A. Bordes et al. "Translating Embeddings for Modeling Multi-relational Data". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2013.

目录

1 背景介绍

2 相关工作

3 研究方法

4 实验结果

5 总结与展望

相关工作概述

传统方法

1. 基于规则的抽取方法
2. 基于统计模型的方法
3. 基于深度学习的方法

LLM-based 方法

1. Prompt Engineering
2. Instruction Tuning
3. In-context Learning

Research Gap: 现有 LLM 方法在 低资源场景 和 跨领域迁移 方面仍存在不足。

目录

1. 背景介绍
2. 相关工作
3. 研究方法
4. 实验结果
5. 总结与展望

模型框架

核心思想：利用 LLM 的上下文学习能力，通过 **检索增强生成** (Retrieval-Augmented Generation)[2] 实现知识三元组的精确抽取。

目标函数：

$$\mathcal{L} = -\sum_{(h,r,t)\in\mathcal{G}} \log P_\theta(t \mid h, r, \mathcal{C}) + \lambda\|\theta\|_2^2 \tag{1}$$

收敛性保证

在学习率 $\eta < \frac{2}{L}$（L 为 Lipschitz 常数）的条件下，上述优化过程以 $O(1/\sqrt{T})$ 的速率收敛。

[2] P. Lewis et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2020.

算法流程

Algorithm 1: RAG-based Knowledge Extraction

Input: Document set $\mathcal{D}$, LLM $\mathcal{M}$, Knowledge base $\mathcal{K}$
Output: Knowledge Graph $\mathcal{G}$

$\mathcal{G} \leftarrow \emptyset$;
foreach $d \in \mathcal{D}$ **do**
  $\mathcal{C} \leftarrow \text{Retrieve}(\mathcal{K}, d)$; triples $\leftarrow \mathcal{M}(d, \mathcal{C})$;
  foreach $(h, r, t) \in$ *triples* **do**
    if *Verify*$(h, r, t, \mathcal{K})$ **then** $\mathcal{G} \leftarrow \mathcal{G} \cup \{(h, r, t)\}$;
  end
end
return $\mathcal{G}$;

代码示例

Listing 1: LLM Extraction Pipeline

```python
import torch
from transformers import AutoModelForCausalLM, AutoTokenizer

def extract_triples(text: str, model, tokenizer) -> list:
    """Extract knowledge triples from text using LLM."""
    prompt = f"Extract (head, relation, tail) from:\n{text}"
    inputs = tokenizer(prompt, return_tensors="pt")
    outputs = model.generate(**inputs, max_new_tokens=256)
    result = tokenizer.decode(outputs[0], skip_special_tokens=True)
    return parse_triples(result)
```



目录

1 背景介绍

2 相关工作

3 研究方法

4 实验结果

5 总结与展望

实验设置与结果

表 1: 不同方法在 NYT 数据集上的性能对比

方法	Precision	Recall	F1
CasRel	89.7	89.5	89.6
TPLinker	91.3	90.0	90.7
GPT-3.5 (ICL)	85.2	82.1	83.6
Ours	**93.1**	**91.8**	**92.4**

Key: 在 F1 指标上超越所有基线；检索增强策略显著提升了 Recall（+9.7% vs. ICL baseline）。

实验分析



(a) P-R 曲线



(b) 消融实验

图 **1:** 实验结果详细分析



目录

1 背景介绍

2 相关工作

3 研究方法

4 实验结果

5 总结与展望

总结与展望

主要贡献

- 提出了 RAG-based 知识图谱构建框架
- 设计了三元组验证机制
- 在多个数据集上取得 SOTA 结果

未来工作

- 探索多模态知识抽取
- 研究增量式图谱更新
- 扩展到更多领域

参考文献 I

[1] J. Wei et al. “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2022.

[2] A. Bordes et al. “Translating Embeddings for Modeling Multi-relational Data”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2013.

[3] P. Lewis et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2020.



Thank You!

张 三

南开大学　计算机学院

2026 年 5 月 24 日

欢迎批评指正　·　Q & A