

南開大學
Nankai University

基于大语言模型的知识图谱构建方法研究

博士研究生学术汇报

张 三
南开大学　计算机学院
2026 年 10 月 20 日

允公允能　日新月異

目录

1. 背景介绍
2. 相关工作
3. 研究方法与理论分析
4. 实验结果
5. 总结与展望

目录

1 背景介绍

2 相关工作

3 研究方法与理论分析

4 实验结果

5 总结与展望

研究背景

- 知识图谱嵌入通过向量表示实体与关系[1]
- 思维链提示为大语言模型（LLM）推理提供了一种方法[2]
- 检索增强生成结合外部知识与语言模型[3]
- 本示例关注的研究问题：
  - 实体识别与链接的准确率有待提升
  - 关系抽取在长尾分布下效果不佳
  - 缺乏统一的端到端构建框架

> 示例主题：结合 LLM 的语义理解能力，探索领域知识图谱构建。

[1] A. Bordes et al. “Translating Embeddings for Modeling Multi-relational Data”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2013.

[2] J. Wei et al. “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2022.

[3] P. Lewis et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2020.

任务定义与示例约定

从文档到知识三元组

输入：文档集合 $\mathcal{D}$ 与可检索知识库 $\mathcal{K}$。

输出：经过验证的三元组集合 $\widehat{\mathcal{G}} = \{(h, r, t)\}$。

评价：Precision、Recall、F1 与推理时延。

如何阅读本示例

后续方法、代码与合成实验数据用于演示学术汇报排版，不代表真实实验结论。引用的论文用于介绍相关概念。

基本概念

知识图谱 (Knowledge Graph)

知识图谱是一种用图结构来建模和存储现实世界中实体及其关系的技术，通常表示为三元组集合 $\mathcal{G} = \{(h, r, t)\}$，其中 $h, t \in \mathcal{E}$（实体集），$r \in \mathcal{R}$（关系集）。

TransE 评分函数

TransE 用平移关系 $\boldsymbol{h} + \boldsymbol{r} \approx \boldsymbol{t}$ 建模三元组，定义距离评分 $f(h, r, t) = \|\boldsymbol{h} + \boldsymbol{r} - \boldsymbol{t}\|_2$；较小的距离表示更高的模型可信度。[4]

[4] A. Bordes et al. "Translating Embeddings for Modeling Multi-relational Data". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2013.

目录

1 背景介绍

2 相关工作

3 研究方法与理论分析

4 实验结果

5 总结与展望

相关工作概述

传统方法

1. 基于规则的抽取方法
2. 基于统计模型的方法
3. 基于深度学习的方法

LLM-based 方法

1. Prompt Engineering
2. Instruction Tuning
3. In-context Learning

研究切入点：如何评价检索与验证模块在低资源场景下的作用?

目录

1 背景介绍

2 相关工作

3 研究方法与理论分析

4 实验结果

5 总结与展望

模型框架

核心思想：利用 LLM 的上下文学习能力，通过 **检索增强生成** (Retrieval-Augmented Generation)[5] 实现知识三元组的精确抽取。

目标函数：

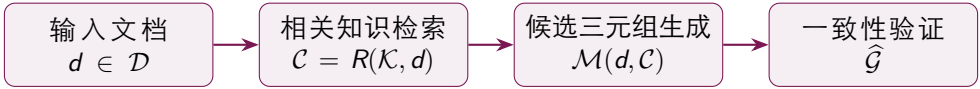
$$\mathcal{L} = -\sum_{(h,r,t)\in\mathcal{G}} \log P_\theta(t \mid h, r, \mathcal{C}) + \lambda\|\theta\|_2^2 \tag{1}$$

建模说明

$\mathcal{C}$ 为检索上下文，$\lambda \geq 0$ 为正则化系数。本目标函数仅作数学排版示例；具体优化性质需结合模型与假设分析。

[5] P. Lewis et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2020.

检索、生成与验证



每个模块分别记录输入、输出与运行时间，便于复现和消融分析。

评分函数的稳定性

引理：反三角不等式

对任意向量 $\boldsymbol{x}, \boldsymbol{y}$ 及同一种范数，$\big|\|\boldsymbol{x}\| - \|\boldsymbol{y}\|\big| \le \|\boldsymbol{x} - \boldsymbol{y}\|$。

定理：TransE 距离评分的扰动上界

设 $f(\boldsymbol{h}, \boldsymbol{r}, \boldsymbol{t}) = \|\boldsymbol{h} + \boldsymbol{r} - \boldsymbol{t}\|_2$。若各嵌入向量的扰动范数均不超过 ε，则

$$|f(\boldsymbol{h} + \Delta\boldsymbol{h}, \boldsymbol{r} + \Delta\boldsymbol{r}, \boldsymbol{t} + \Delta\boldsymbol{t}) - f(\boldsymbol{h}, \boldsymbol{r}, \boldsymbol{t})| \le 3\varepsilon.$$

扰动上界的证明

证明：两次应用范数不等式

记 $\boldsymbol{x} = \boldsymbol{h} + \boldsymbol{r} - \boldsymbol{t}$，$\boldsymbol{\delta} = \Delta\boldsymbol{h} + \Delta\boldsymbol{r} - \Delta\boldsymbol{t}$。由反三角不等式及三角不等式，

$$\begin{aligned} \big|\|\boldsymbol{x}+\boldsymbol{\delta}\|_2 - \|\boldsymbol{x}\|_2\big| &\le \|\boldsymbol{\delta}\|_2 \\ &\le \|\Delta\boldsymbol{h}\|_2 + \|\Delta\boldsymbol{r}\|_2 + \|\Delta\boldsymbol{t}\|_2 \\ &\le 3\varepsilon. \qquad \square \end{aligned}$$

该界仅说明距离评分对嵌入扰动的稳定性，不等价于抽取准确率保证。

算法流程

Algorithm 1: RAG-based Knowledge Extraction

Input: Document set $\mathcal{D}$, LLM $\mathcal{M}$, Knowledge base $\mathcal{K}$
Output: Knowledge Graph $\mathcal{G}$

$\mathcal{G} \leftarrow \emptyset$;
foreach $d \in \mathcal{D}$ **do**
  $\mathcal{C} \leftarrow \text{Retrieve}(\mathcal{K}, d)$; triples $\leftarrow \mathcal{M}(d, \mathcal{C})$;
  foreach $(h, r, t) \in$ *triples* **do**
    if *Verify*$(h, r, t, \mathcal{K})$ **then** $\mathcal{G} \leftarrow \mathcal{G} \cup \{(h, r, t)\}$;
  end
end
return $\mathcal{G}$;

代码示例

Listing 1: Validate and deduplicate triples (Python 3.9+)

```python
import json

def parse_triples(text: str) -> list[tuple[str, str, str]]:
    """Parse a JSON array of non-empty string triples."""
    data = json.loads(text)
    if not isinstance(data, list):
        raise ValueError("Expected a JSON array")
    triples = {
        tuple(value.strip() for value in item)
        for item in data
        if isinstance(item, list) and len(item) == 3
        and all(isinstance(v, str) and v.strip() for v in item)
    }
    return sorted(triples)
```

目录

1 背景介绍

2 相关工作

3 研究方法与理论分析

4 实验结果

5 总结与展望

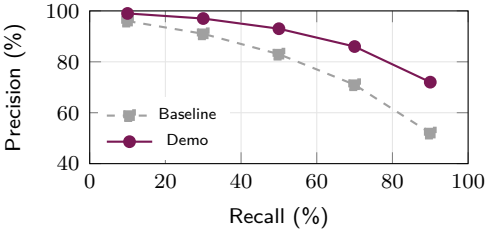
实验设置与结果

表 1: 抽取方法对比（合成数据，仅用于排版演示；指标单位：%）

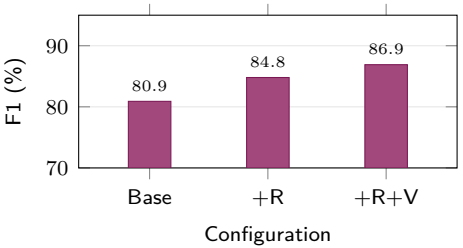
分组	方法 / 配置	Precision	Recall	F1
基线	Baseline A	82.0	76.0	78.9
	Baseline B	86.0	80.0	82.9
示例模型	不使用检索	84.0	78.0	80.9
	完整流程	90.0	84.0	86.9

读表示例：在这组合成数据中，加入检索后 Recall 增加 $84.0 - 78.0 = 6.0$ 个百分点。真实汇报应补充数据来源与不确定性分析。

实验分析



(a) 示例 P-R 曲线



(b) 示例消融：检索 R 与验证 V

图 1: 合成数据：子图 (a) 与 (b) 展示不同分析视角

Reproducibility Checklist

Experimental protocol

- Fix data splits and random seeds.
- Record model and prompt versions.
- Report hardware and latency.

Retrieval baseline

Document the retriever, index, and context budget when evaluating retrieval-augmented generation.[6]

Example settings: memory budget 24 GB; latency budget 120 ms per query. These are illustrative settings.

[6] See P. Lewis et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2020, § 2.



目录

1 背景介绍

2 相关工作

3 研究方法与理论分析

4 实验结果

5 总结与展望

总结与展望

本示例展示的内容

- 问题定义、公式与证明
- 流程图、伪代码与程序代码
- 实验表格、子图与脚注引用

用于真实汇报前

- 替换为真实数据与研究结论
- 补全实验条件和来源
- 核对引用、单位和统计口径

参考文献 I

[1] A. Bordes et al. “Translating Embeddings for Modeling Multi-relational Data”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2013.

[2] J. Wei et al. “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2022.

[3] P. Lewis et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2020.



Thank You!

张 三

南开大学　计算机学院

2026 年 10 月 20 日

欢迎批评指正　·　Q & A

附录：实验配置记录

表 2: 可复现实验记录示例（配置值仅作演示）

项目	记录内容
随机种子	$\{7, 21, 42\}$；报告多次运行的均值与标准差
检索设置	Top-$k = 5$；固定索引版本、分词方式及上下文截断规则
硬件预算	显存 24 GB；记录设备型号与软件版本
评价协议	按三元组精确匹配；明确 micro / macro 平均及去重规则
资源入口	`https://www.nankai.edu.cn`

附录编号

附录使用独立的当前页 / 总页数；封面与致谢页不计入正文页数。